本地部署大模型，究竟用多少才划算？

消费级显卡、开源推理引擎与低价在线 Token 的横向比较

lawyer112

2026 年 10 月 28 日

摘要　借助专家卸载，12–24 GB 的游戏显卡加 64 GB 内存已能运行 1250 亿参数的 Qwen3.8-Flash-Next（Strata 方案）；更大的 DeepSeek 模型仍需单卡配大容量主存，或 128 GB 统一内存设备。本文把这些路线与 DeepSeek 直连 API、Command Code Go／GOAT、OpenCode Go／Plus 放入同一成本框架，并整理了一台 RTX 4090 主机上的 Strata 记录：测速套件中短对话解码中位数为 102.4 Token/s，而 613 个实际请求在长上下文下的中位数只有约 32–34 Token/s，每个忙碌小时约产出 7.1 万个输出 Token。按这一实测负载，每月 120 个忙碌小时的 DeepSeek 直连费用为 185 元（全按空闲时段）至 370 元（全按高峰），GOAT 或 OpenCode Go 的 10 美元月费（约 66.77 元）即可覆盖。新购一台约 1.66 万元的 RTX 5070 主机，要在 36 个月内回本，需要每月约 167 个忙碌小时，且原本要按高峰价直连付费；若对比 GOAT，即使全按高峰计价也需要约 329 小时。按同样口径，Mac Studio 和 DGX Spark 需要 400 小时以上，5090 加 256 GB 内存的主机在一个月内达不到。已有游戏主机的现金成本与低价套餐相近，取舍在于隐私、控制、等待时间与质量。本文未评测回答质量；本机记录只覆盖一台机器、一个去限制微调版本和一位用户约一周的使用。

一、能跑起来，与买机器能回本，是两回事

本地大模型的门槛在 2026 年明显下降。混合专家模型每个 Token 只激活少量参数，推理引擎因此可以把常用专家放进显存，其余专家放进内存甚至 SSD。Strata 用这种办法，在 12 GB 以上的游戏显卡加 64 GB 内存上运行 1250 亿参数的 Qwen3.8-Flash-Next；KTransformers、FreeToken 用单张显卡加数百 GB 主存运行 DeepSeek；DwarfStar 面向 128 GB 统一内存的 Mac 和 DGX Spark。[1], [2], [3], [4]

在线一侧同样变了。几家编码工具把 1 美元或 10 美元的月费换成数倍于月费的模型额度；DeepSeek 按时段分两档计价，高峰价是空闲价的两倍。[5], [6], [7] 因此，“能不能跑”和“值不值得买”需要分开回答。本文依次回答四个问题：各路线需要什么硬件；实际使用中跑多快；同样的工作量在线要花多少钱；新购或已有的设备要用到多少才划算，以及现金以外还有哪些回报。

二、已有认识与本文的补充

常见估算把显卡价格与 API 单价或租用价格直接相除。例如价格聚合站 VRAMGlass 按每天使用 4、8、24 小时，比较买一张 3090 与按小时租用的回本年数，并注明不计残值和整机其他部件。[8] 这类估算便于判断量级，但通常遗漏三件事：整机的其余部件，尤其是 2026 年大幅涨价的内存；单流测速与实际 Agent 长上下文使用之间的差距，FreeToken 论文也指出单流基准会高估 Agent 场景性能；以及最便宜的在线替代往往是附带大额度的套餐，而不是 API 标价。[3], [9]

本文的补充有三点：按来源整理各路线的硬件条件与作者报告的速度；用一台 4090 主机上的实测记录估计实际吞吐和 Token 结构；再用同一套“忙碌小时”口径，计算在线账单与本地设备回本所需的使用量。

三、材料与方法

价格、套餐、软硬件与汇率按 2026 年 10 月 26—27 日所核验的资料截点处理；本文是该截点的情景核算，不是发布日的即时报价。服务规则变化后须重新取价和计算，不能将表中门槛直接当作当前购买结论。本文区分五类证据：**官方说明**用于支持范围和计费规则；**作者报告**用于特定条件下的性能；**第三方报价**用于价格量级；**本机实测**来自一台 RTX 4090 主机的测速与日志；**本文假设**用于情景计算。前四类各有出处或原始记录，最后一类在表中逐项标明。

本机记录有两部分。第一部分是 2026 年 10 月 12 日安装后用 Strata 自带工具运行的测速套件，每项 3 次，关闭思考，温度为 0，只测速度。第二部分是引擎日志：每个请求记录提示 Token 数、复用数、读取耗时、生成 Token 数和生成耗时，不记录内容。分析窗口从 10 月 12 日 21:37 安装验收结束后的首次重启开始，到 10 月 20 日最后一次启动为止，共 5 次引擎启动、613 个请求；更早的安装、验收与客户端调试请求不计入。解析脚本与派生数据见第十三节。

本文没有评测回答质量，没有测量功耗，没有在其他机器上复测，也没有用付费账户验证套餐。价格采用 2026 年 10 月 26 日的页面快照；美元套餐按当日参考汇率 1 美元＝6.6774 元换算，未含支付手续费；DeepSeek 直连采用其中文页面的人民币价。[10] 模型、推理引擎与托管服务是三个层次：同名的在线 Flash 不能自动视为本地某个量化文件的等价替代。

四、本地路线：装得下什么，标称跑多快

1. Qwen3.8-Flash-Next：一张游戏卡加 64 GB 内存即可起步

Qwen3.8-Flash-Next 由 1250 亿参数的主模型和 510 亿参数的 N-gram 嵌入组成，每个 Token 激活约 60 亿参数；官方说明 N-gram 表可以放在主存。[11] 激活量小、查表数据大，是它能在消费级硬件上运行的原因，也是不同引擎内存布局差别很大的原因。

路线	容量条件	起步硬件	作者报告的速度
Strata（IQ3_XXS 等）	IQ3_XXS 需内存加显存 47.0 GB，Q2_0 为 37.6 GB；约 29 GB 查找表留在 SSD；下载 66–76 GB，另需约 6 GB 的 MTP 草稿层	12 GB 以上显卡、64 GB 内存（32 GB 只能跑 Coder 版）	RTX 5070＋64 GB：IQ3_XXS 短对话 62、128K 上下文 49、读提示 1,750 Token/s
Unsloth GGUF＋llama.cpp	1–4 bit 约需 75、79、90、96–114 GB 总内存	96–128 GB 级设备	未列出
DwarfStar	Q2 文件 137.10 GiB、常驻 41.73 GiB；Q4 为 165.11／69.74 GiB；95.37 GiB N-gram 表留在 SSD	64 GB Mac（8K 上下文）到 128 GB Spark	Spark：Q2 22.6、Q4 21.2 Token/s（8K，教师强制）
FreeToken	N-gram 表 47.7 GiB 固定在主存	消费级 RTX＋大主存	本文未取得

来源：项目文档。速度为作者报告，本文只对 Strata 做了单机实测（第五节）。[4], [12], [13], [14]

Strata 把最常用的专家放进显存，全部专家放进内存，查找表放在 SSD，并用 MTP 草稿层做投机解码；作者称投机解码不改变答案，可提速 1.6–1.8 倍。[1] 有两点需要和速度一起读。第一，0.1.42 起 Strata 在 N 卡上默认跳过验证窗口内排名靠后、又不在显存里的专家，其贡献记为零；作者测得与精确计算相比，逐 Token 最可能输出的一致率为 97.5%–98.2%，设 `STRATA_ROUTE_TAIL_SKIP=0` 可关闭，单卡解码会慢一成多。[15] 第二，默认一次只服务一个请求，并发需另行设置。作者还估计 24 GB 的 RTX 3090 可达约 100–140 Token/s，这是估算，不是测量。[12]

作为对照，稠密的 Qwen3.8-27B 约 278 亿参数，全部按 4 bit 计裸权重约 13.9 GB，可用 llama.cpp 放进一张 24 GB 显卡；它比 Flash-Next 小得多，不能当作同一模型的低配版。[16], [17]

2. DeepSeek：单卡之外，还要大主存或 SSD 流式

路线与模型	硬件条件	作者报告的速度	阅读限制
KT-Kernel＋SGLang，V4-Flash-0731	验证配置为单张 5090 32 GB、至少 200 GB 内存、约 340 GB 存储；3090、4090、5090 架构均标为已验证	20+ Token/s（5090）	16K 上下文、最多 2 个请求、关闭前缀缓存、60 个 CPU 推理线程
FreeToken，V4-Flash MXFP4	5090；论文使用限 6–8 线程的租用服务器和一台台式机	四类 Agent 负载 22–25 Token/s	作者结果，未复测
FastLLM，单 GPU＋NUMA	给出启动命令	未收录正式吞吐	不能用 TP8 数据外推
DwarfStar，V4-Flash Q2（约 81 GiB）	96／128 GB 设备	M5 Max：2K 时 39.35、16K 时 36.14；Spark：18.05、15.10	128 Token 贪心探针
V4.1-Flash-1017（与在线 API 同款）	DwarfStar Q2 文件 341 GiB、主权重 152 GiB，单台 128 GB 设备需 SSD 流式；Strata 0.2.5 需 245–280 GB 硬盘	Strata：RTX 5070＋64 GB 为 4–6、RTX 3060＋46 GB 为 9–11 Token/s	2.00 bpw；作者结果

来源：项目文档与 FreeToken 论文。[2], [3], [18], [19], [20], [21]

这张表有两层含义。其一，“单张消费卡”背后通常是 200 GB 以上的主存，预算不能只算显卡。其二，与在线 API 同款的 V4.1-Flash 已经能在 64 GB 游戏机上运行，但每秒只有几个到十几个 Token；用它替代在线 Flash，意义主要在于离线和自主控制，而不在于省钱。FreeToken 论文还报告，某些引擎在 Agent 多轮负载下比单轮测试慢三成，首字延迟的尾部可达数百秒。[3]

3. 读这些速度时要注意什么

预填充（读入提示）和解码（逐个生成）是两个指标。上表的速度来自不同作者、不同上下文和不同协议：DwarfStar 的 Spark 数据采用教师强制解码，Strata 的数据包含投机解码和默认的专家跳过。它们只能说明量级，不能拼成统一排行榜。

五、一台 RTX 4090 主机上的实测

1. 配置

机器为 RTX 4090 24 GB、Ryzen 7 7800X3D、64 GB 内存、Windows 11；Strata 0.1.43（提交 7695859）；模型为 Huihui 发布的 Qwen3.8-Flash-Next Swift IQ3_XXS 去限制版，两个模型文件共 75,966,073,120 字节，SHA-256 与固定版本一致。[22] 配置为 256K 上下文、8-bit KV 缓存、显存保留 32,768 个 KV 单元、专家内存预算 26 GiB（其余专家经文件缓存读取），启用 MTP 投机解码，一次服务一个请求。去限制只改变拒答倾向，不改变硬件需求；Swift 是缩短思考的微调版，二者都不是官方原版。[23]

2. 测速套件

测试	规模	速度（中位数，范围）	其他
短对话	9 次，每次生成 100 Token	解码 102.4（87.4–119.2）Token/s	首字 0.26 秒
新提示读取	4K／16K／32K	读入 2,375／3,562／3,663 Token/s	首字 1.71／4.55／8.78 秒
Agent 续轮	5 轮，末轮约 1.45 万 Token	解码 119.7（88.8–158.0）Token/s	缓存命中 68.6%
长上下文检索	255,980 个输入 Token	未单列	三个位置均找到；每次 70–75 秒

测速期间，系统提交内存峰值为 73.94 GiB，上限 79.10 GiB，可用物理内存最低 8.61 GiB。运行模型时，这台电脑基本不能同时承担其他重负载。

3. 实际使用

分析窗口内共 613 个请求，引擎忙碌（读提示加生成）合计 5.09 小时，其中 66.2% 用于解码。平均每个请求的提示约 9.4 万 Token，其中 90.7% 来自前缀复用；共新读入 535 万 Token，生成 36.3 万 Token。折算下来，每个忙碌小时约生成 71,319 个输出 Token，新读入约 105 万个、复用约 1,027 万个提示 Token，全程平均解码速度为 29.9 Token/s。日志不记录调用方；这样长的提示和这样高的复用率，与编码 Agent 每轮重发整段上下文的方式一致。

在生成 64 个以上 Token 的请求中，提示长度在 32K–64K 的中位数为 31.8 Token/s（P10–P90 为 11.6–55.4，143 个请求），64K 以上为 33.9 Token/s（18.3–52.5，415 个）。未复用、超过 1.6 万 Token 的新提示共 79 个，读入速度中位数 1,064 Token/s，等待中位数 40.8 秒。五次启动的解码中位数依次为 49.7、45.9、29.7、12.0 和 13.9 Token/s；10 月 20 日还出现一次读提示阶段 60 秒无进展的卡顿报告。本文没有排查原因。

4. 这些数字能说明什么

短对话测速约 100 Token/s，实际长上下文使用只有约三分之一，而且会话之间波动很大。估算产能应使用实际负载下每个忙碌小时的产出，而不是测速峰值。同时，这组记录只来自一台机器、一个去限制微调版本和一位用户约一周的使用。本机为容纳 256K 上下文设置了 26 GiB 专家内存预算，可能慢于较小上下文的配置，但本文没有做对照实验。

六、硬件价格与整机预算

VRAMGlass 汇总闲鱼在售挂单，取中位数并按卖家去重，排除矿卡、配件和整机等，不是成交价。[24] 下表统一采用 2026 年 10 月 26 日 19:41 的页面快照。

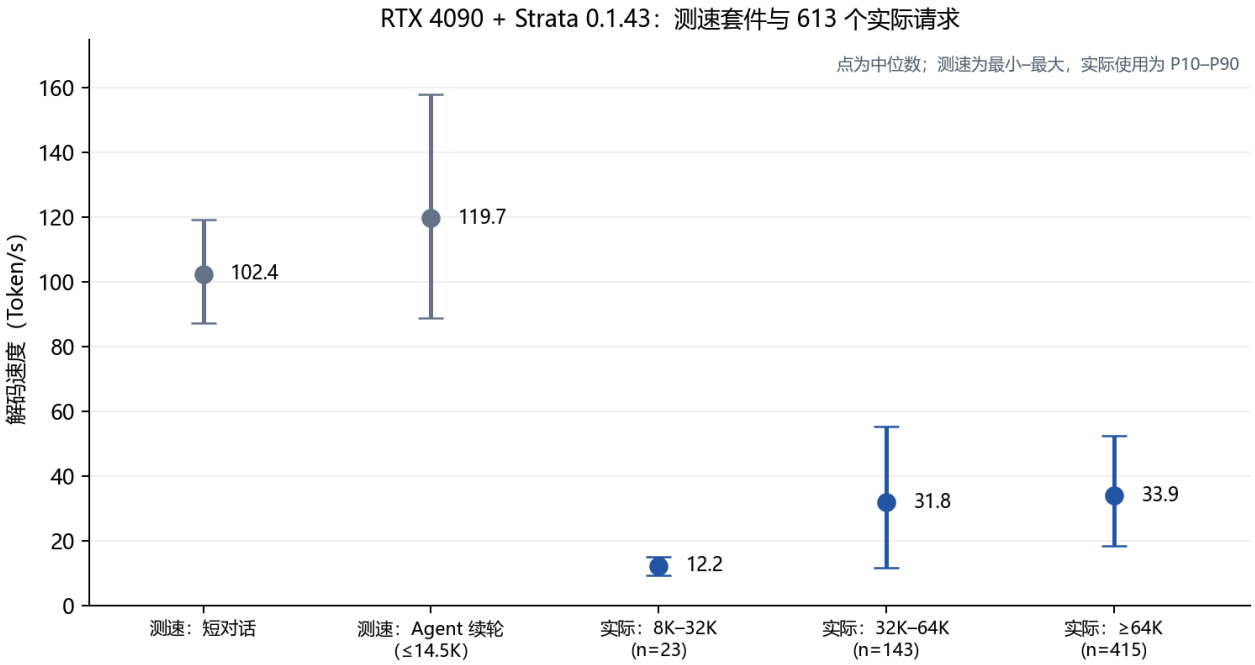


图 1　RTX 4090＋Strata 0.1.43 的测速套件与实际请求。点为中位数，测速为最小至最大值，实际使用为 P10 至 P90；8K–32K 区间的 23 个请求全部来自 10 月 20 日的两次慢速会话。

设备	二手中位价（元）	页面所列官方价（元）	备注
RTX 3090 24 GB	8,500	10,009	2020 年发布价；多为二手
RTX 5070 12 GB	7,586	3,666	Strata 作者测试机所用显卡
RTX 5090 32 GB	52,349	13,348	挂单可能混入 5090 D／D V2（24 GB）
Mac Studio M5 Max 128 GB	42,000	未列出	具体配置未核实
DGX Spark 128 GB	44,050	26,703	新出的 64 GB 版可能混入挂单

来源：VRAMGlass 各设备页。[8], [25], [26], [27], [28]

除 3090 外，二手价都明显高于页面所列官方价，说明 2026 年的显卡行情紧张，也意味着三年后的残值难以预测。内存同样涨价：秋叶原 10 月上旬的调查中，64 GB 的 DDR5 台式机套装最低约 9.8 万日元、均价约 12.7 万日元，按参考汇率约合 4,200–5,400 元；一份 9 月 20 日的服务器内存目录中，64 GB DDR4 RDIMM 的中位价为 929 美元，DDR5 为 3,186 美元。[9], [29] 这些是海外行情，只用于判断量级。

情景	一次投入 K（元）	构成与运行路线
A：RTX 5070＋64 GB 主机	16,586（14,586–18,586）	显卡 7,586＋其余部件预留 7,000–11,000；用 Strata 跑 Next，对应作者测试机

情景	一次投入 K（元）	构成与运行路线
B：RTX 5090＋256 GB 主机	76,349（65,349–87,349）	显卡 52,349＋其余部件预留 13,000–35,000；用 KT 或 FreeToken 跑 DeepSeek
C：Mac Studio M5 Max 128 GB	42,000	整机；DwarfStar 等
D：DGX Spark 128 GB	44,050	整机；另按官方价 26,703 元做敏感性
E：已有 RTX 4090＋64 GB 主机	0	本文实测机，只计新增运行费用

其余部件均未询价，按区间处理。A 的预留覆盖 CPU、主板、64 GB 内存、电源、NVMe 和机箱；B 的 256 GB 服务器内存单项就可能在 7,800 元（库存最低价的 DDR4 条）到 24,800 元（中位价）之间，DDR5 平台更贵。3090 比 5070 显存大，但本文没有它的 Strata 实测数据。

七、在线方案：额度、时段与折扣

1. 同一个 DeepSeek-V4.1-Flash，四种买法

方案	价格与额度	使用边界
DeepSeek 直连	空闲时段每百万 Token：未命中输入 1 元、缓存命中 0.02 元、输出 4 元；高峰翻倍	可编程调用；高峰为北京时间工作日 9–12 点、14–18 点
Command Code Go	1 美元／月，DeepSeek V4.1 Flash 额度 10 美元	仅限 Command Code 客户端，无 API
Command Code GOAT	10 美元／月，额度 80 美元	有 Provider API
OpenCode Go	10 美元／月，额度 80 美元	面向编码 Agent 流量
OpenCode Go Plus	40 美元／月，额度 160 美元	同上

来源：服务商定价与计划页面。套餐按美元标价计入额度，DeepSeek 的高峰价同样计入。[5], [6], [7], [30], [31], [32]

额度是**共享池**。例如在 OpenCode Go 上用掉 20 美元 DeepSeek 额度和 7.5 美元 Qwen3.8 Flash 额度，池子已用 20/80＋7.5/30＝50%。[6] 短期窗口也会先于月额度起作用：OpenCode 为 5 小时 20%、每周 50%；GOAT 为 5 小时 14、每周 35 个额度单位。Command Code Go 的文档自相矛盾：计划页写 5 小时 3、每周 6，用量表写 2／5，本文保留这一冲突。超过窗口或额度后，Command Code 改用按模型价计费的充值额度，充值额度不受窗口限制；OpenCode 开启 Extra Usage 后回落到余额。[33], [34]

结算细节同样影响账单：Command Code 最少充值 5 个额度，充值额度可结转、订阅额度不结转，因此当月扣款可能高于归属本月消耗的成本。[35] 条款也常变：Command Code Go 自 9 月 28 日起改为按模型分配额度，并声明额度可能随时调整。[31]

2. “半价”出现在三个不同层面

类型	例子	处理
时段价	DeepSeek 空闲价为高峰价的一半，高峰正好是工作日白天	按请求发生时间计价；下文给出全空闲与全高峰两个边界
平台优惠	Command Code 的 MiniMax M3 五折，仅当打折的上游提供服务时生效	已包含在 GOAT 给 MiniMax M3 的 47 美元月用量中，不能再叠加
厂商介绍价	Gemini 4 Argon 的 2／10 美元是 Google 定到 11 月 30 日的介绍价，12 月 1 日起为 4／20 美元	OpenCode 标作“五折”，其他渠道同价；不能外推到三年

来源：服务商与模型厂商定价页。[6], [7], [34], [36], [37]

以 5,000 万输入、1,000 万输出 Token 为例，MiniMax M3 原价 54 美元、折后 27 美元（约 360.6 元和 180.3 元）。GOAT 给 MiniMax M3 的 47 美元月用量已包含这项优惠，但页面没有写明它按标价还是按折后价计：若按折后价扣减，这笔用量在额度内，月费即可覆盖；若按标价计，54 美元超出 7 美元。本文没有用付费账户核实。[34] Google 的 Batch 与 Flex 档也是半价，适合不需要即时回复的批量任务。[37]

八、同一负载的在线账单

把第五节的实测负载搬到在线 API：每个忙碌小时约 105 万个新输入、1,027 万个缓存命中输入和 7.1 万个输出 Token。按 DeepSeek 人民币价，每个忙碌小时在空闲时段约 1.54 元，高峰约 3.08 元；空闲时段的费用中，新输入占 68.2%，缓存命中占 13.3%，输出占 18.5%。

每月忙碌小时（空闲／高峰，元）	轻量 30 小时	中量 120 小时	重量 240 小时
DeepSeek 直连	46.25／92.51	185.02／370.03	370.03／740.07
Command Code Go	6.68／32.56	125.22／310.53	310.53／681.17
Command Code GOAT	66.77／66.77	66.77／66.77	66.77／273.84
OpenCode Go	66.77／66.77	66.77／66.77	66.77／273.84
OpenCode Go Plus	267.10／267.10	267.10／267.10	267.10／267.10

套餐成本＝月费＋max（0，按量费用－该模型额度），是按本月消耗归属的成本，不是保证扣款额。GOAT 的 80 美元额度约可覆盖 346 个空闲时段忙碌小时，或 173 个高峰忙碌小时；Go 的 10 美元只够约 43 或 22 小时。

几项敏感性：若在线缓存命中率为 95%（本机为 90.7%），空闲时段每个忙碌小时的费用降至约 1.07 元；一次性读入、不复用上下文的文档任务（输入为输出的 5 倍、无缓存），每百万输出 Token 的直连费用约 9 元（空闲）或 18 元（高峰）；若以托管的 Qwen3.8 Flash 作同模型基准（是否与开源权重相同未核实），每个忙碌小时约 2.37 元。不同模型的分词器不同，同一任务的 Token 数也会有出入。

就这一负载而言，每月约 30 小时的轻度使用，能在 Command Code 客户端内完成的工作用 Go 最省；需要 API 时，直连在空闲时段约 46 元，低于 GOAT，全在高峰时约 93 元，高于 GOAT。每天几小时的个人编码，GOAT 或 OpenCode Go 的固定月费最低；只有远超额度时才轮到 Plus。

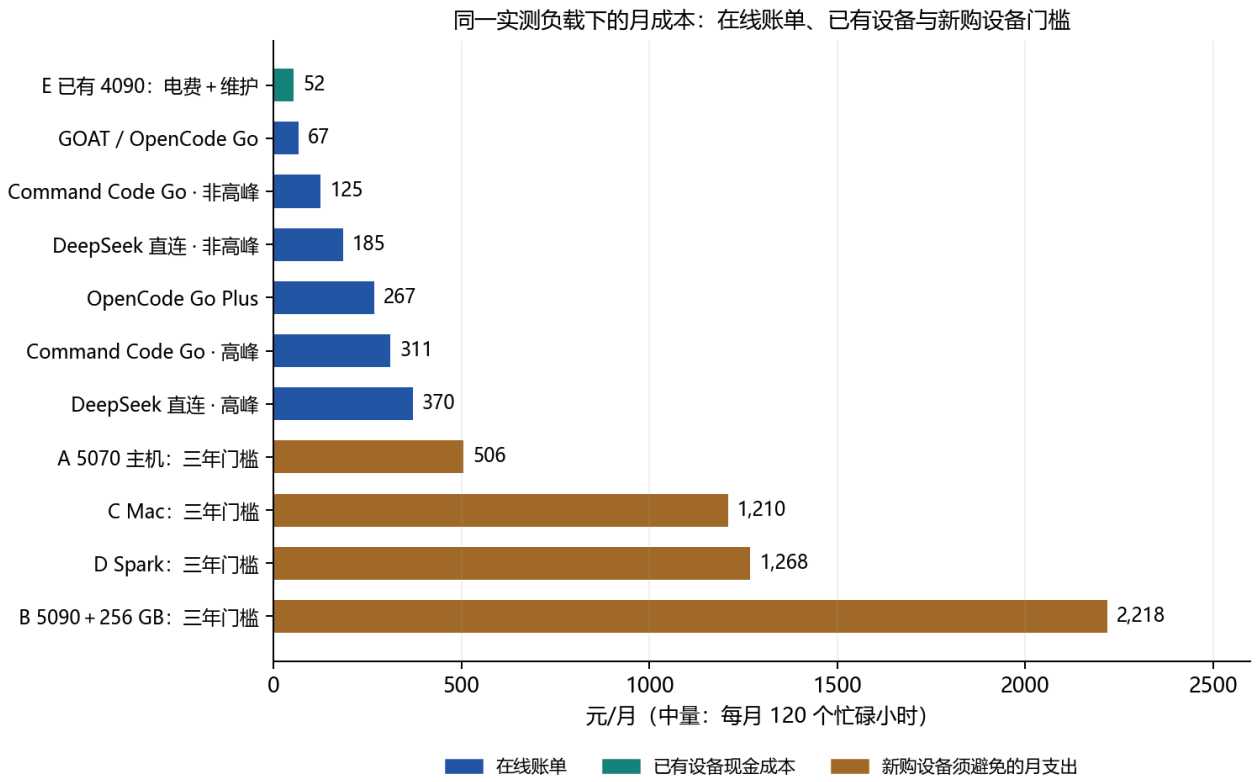


图 2　每月 120 个忙碌小时的实测负载：在线账单、已有设备的现金成本，以及新购设备在 36 个月内须避免的月支出。

九、回本：要用多少才划算

1. 公式

记一次投入为 K，残值比例为 r，每月忙碌小时为 H。本地每月运行费 O＝功率×H×0.6 元/kWh＋维护费；电价和功率均为假设，空闲待机不计。要在 36 个月内回本，每月真正避免的在线支出不能少于：

三年门槛＝K×（1－r）／36＋O。

把每个忙碌小时可替代的在线费用记为 v（直连空闲时段 1.54 元，高峰 3.08 元），回本所需的忙碌小时为：

H*＝［K×（1－r）／36＋维护费］／（v－每小时电费）。

对比套餐时，额度以内每多用一小时都不增加套餐费用，本地最多只能省下固定月费；超出额度的部分才按 v 计。本文据此求出对比 GOAT 的 H*。

2. 结果

情景	120 小时的三年门槛（元/月）	对比直连·高峰（小时/月）	对比直连·空闲	对比 GOAT·高峰
A：5070 主机	506（450–561）	167（148–187）	361	329
B：5090＋256 GB	2,218（1,912–2,523）	806（693–919）	超过 720	超过 720
C：Mac Studio	1,210	402	超过 720	558
D：DGX Spark	1,268	423	超过 720	580
E：已有 4090	52（现金成本）	7	16	已低于月费

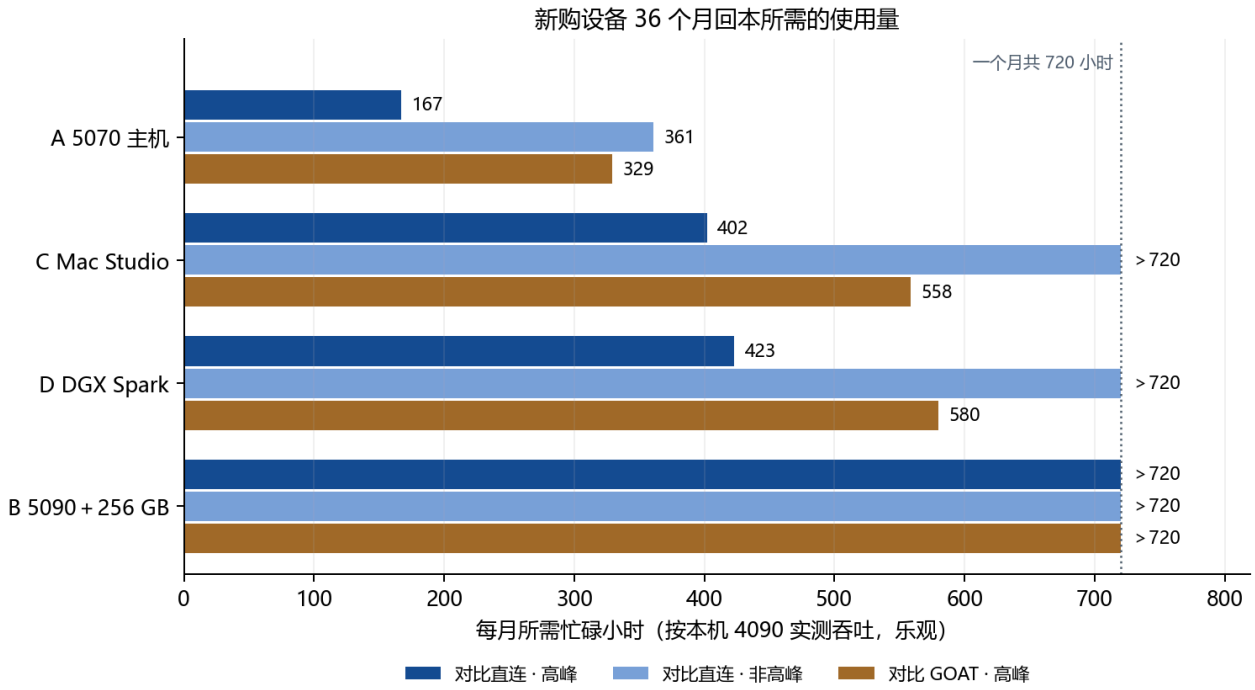


图 3　新购设备在 36 个月内回本所需的每月忙碌小时；超过 720 小时即一个月内无法达到。

括号内为其余部件预留取低值与高值时的结果。忙碌小时只计引擎实际处理请求的时间，不含用户思考和工具执行的间隙，实际开机时间会更长。一个月共 720 小时，240 小时约相当于每天持续忙碌 8 小时。上表假设各设备都能达到本机 4090 的实测吞吐，这对 A、B、C、D 都偏乐观；A 至 E 的功率依次假设为 0.35、0.65、0.18、0.20、0.45 kW。

可以这样理解 A：如果原本每天要按高峰价直连付费、持续用满五六个小时，一台约 1.66 万元的 5070 主机有可能在三年内收回成本；每月 240 小时时，简单回本期约 24.8 个月（21.8–27.8）。但只要改用 GOAT，就需要每月约 329 个忙碌小时，几乎全天持续工作才划算。低价套餐若取消或大幅缩水，就应改看对比直连的那一列。会话间的吞吐差异对这一结论影响有限：按五次启动各自的负载结构计算，A 对比高峰直连所需的小时数在 119–195 之间。

残值会降低门槛。按三年后残值 30% 计，A、C、D 对比高峰直连所需的小时数降至约 119、285、299；残值 50% 时约为 87、206、217。若 DGX Spark 能按页面所列官方价 26,703 元买到新机，120 小时的门槛降至约 786 元，对比高峰直连约需 260 小时；新机在国内能否按此价购得，本文未核实。

3. 已有设备

E 只计新增运行费用：每月 30／120／240 个忙碌小时的电费加维护约 28／52／85 元。对比高峰直连，每月可省约 64／318／655 元；对比 GOAT（高峰），只省约 39／14 元，到超出额度的 240 小时才省约 189 元。也就是说，已有游戏主机自己跑模型，现金上与低价套餐相差无几。按本机这约 8 天的实际强度折算，每月只有约 19 个忙碌小时，属于轻量一档：这时本机现金成本约 25 元，直连约 29–59 元，GOAT 为 66.77 元，而能在 Command Code 客户端内完成的工作用 Go 只需 6.68 元。真正的取舍在别处：运行时内存几乎被占满；超过 1.6 万 Token 的新提示要等几十秒；会话间速度波动并出现卡顿；默认的专家跳过是近似计算；去限制微调版的回答质量未经评估。

4. 替代高价模型时，情况不同

如果本地模型真能替代高价模型，例如按 Gemini 4 Argon 介绍价计每个忙碌小时约 25.66 元的支出，A 每月约 19 个忙碌小时即可回本。这正是需要质量评测的地方：量化后的 Next 能否完成原本交给高价模型的任务，本文没有证据。

5. 租用 GPU 是另一条路

VRAMGlass 页面列出的按需租用价为 3090 每小时 1.13 元、5070 每小时 1.7 元、5090 每小时 3.79 元，每月 120 小时分别约 136、204、455 元；租用按开机时长计费，实际花费只会更高。[8], [25], [26] 需要自有或修改过的权重、但不要求离线的用户，应先与租用比较；租用实例能否提供 Strata 所需的 64 GB 内存和高速 SSD，本文未核实。

十、回报分成三笔账

第一笔是**少付出去的钱**。只有原本确实会支付、改成本地后能取消的 API 或订阅费用，才算现金节省。如果高价在线模型仍需保留，本地部署可能只是新增一项支出。

第二笔是**时间与能力的价值**，可正可负。离线处理、固定版本、可修改权重，可能让某些工作更顺手；安装调试、维护、长上下文等待和失败重做则会占用时间。以每小时 50 元估价，每月净省 10 小时价值 500 元，净多花 10 小时则是负 500 元。这是示意估值，不是现金收入，也不要与业务利润重复计算。

第三笔是**业务净贡献**。假设某项文档服务每个合格任务在扣除任务层面的人工与获客成本后贡献 2 元，A 情景在每月 120 小时下要覆盖约 506 元的三年门槛，至少需要 253 个合格任务。本文没有证据证明这些订单存在，也没有证明机器能按时完成。同一业务也可以用便宜的 API 交付，应比较两种方案的增量净利润。闲置时出租显卡也是一种回报，市场租价给出了每卡时价值的上限，平台抽成与实际出租率未知。

部署前还要核对模型与软件的许可条件：Strata 采用 MIT 许可，但各模型及其去限制、微调版本另有许可。[1]

十一、如何选择，以及下一步怎样实测

当前条件	优先比较	购买或迁移前要验证
偶尔使用，每月少于约 40 个忙碌小时	直连按量；能在指定客户端内完成时看 Go	地区与模型可用性
每天个人编码	GOAT、OpenCode Go	工具兼容、短期窗口、共享额度
已有 12–24 GB 显卡和 64 GB 内存	Strata 跑 Qwen3.8-Flash-Next	长上下文等待、内存占用、自己任务上的质量、专家跳过设置
已有 128 GB 统一内存设备	DwarfStar 的指定量化文件	文件布局、上下文、首字延迟
已有 5090 和 192／256 GB 主存	FreeToken、KT 混合推理	CPU 内存带宽、首字延迟尾部、稳定性
需要自有或修改权重，但不要求离线	先比较租用 GPU	实例内存、磁盘与数据条款
准备新购整机	先记录一个月的真实账单与忙碌小时，再代入第九节	原本是否按高峰价直连付费，忙碌小时是否超过回本线

建议先用 30–50 个真实任务做小规模试验；这个数量是实践起点，不代表统计充分。固定模型文件、版本、量化、上下文、系统提示和工具配置，记录忙碌小时、实测功耗、合格率、重试次数、人工审核时间和实际账单，再计算：

每个合格任务成本＝（设备分摊＋运行＋在线调用＋维护人工）／合格任务数。

这比“每百万 Token 多少钱”更接近购买决策。

十二、限制与结论

主要限制有五项。第一，本机记录只来自一台 RTX 4090 主机、一个去限制的 Swift 微调版本和一位用户约一周的使用，没有评测回答质量，也没有测量功耗。第二，在线账单假设在线服务的 Token 结构与本机相同，实际的分词与缓存命中会不同。第三，其他路线的速度来自作者的异质测试，本文没有复测。第四，硬件价格为在售挂单中位数，其余部件未询价，内存价格来自海外市场；套餐规则常变，Command Code Go 的窗口冲突未解决，也没有用付费账户验证。第五，所有本地数据都是一次一个请求，没有测试批处理与并发。

在这些限制下，就单用户、一次一个请求的使用而言，目前较稳妥的结论是：

- **对比低价套餐，为省 Token 钱新购设备基本不划算。** 即使是最便宜的 A 主机，也要每月约 329 个忙碌小时，才能在三年内胜过按高峰计价的 GOAT；全按空闲时段计价则约需 711 小时。
- **对比高峰时段的直连 API，便宜的 Strata 游戏主机有机会回本。** 前提是每月约 167 个忙碌小时以上，实际吞吐接近本机记录，模型质量也足以替代；Mac Studio 和 DGX Spark 需要 400 小时以上，5090 加 256 GB 内存的主机在一个月内达不到。
- **已有游戏主机的现金成本与低价套餐相近。** 是否在本地运行，应按隐私、控制、等待时间和质量来决定。
- **判断依据应是自己的忙碌小时和真实账单**，而不是测速峰值，也不是任选一个高价 API 的标价。

十三、材料与复现

中英文全文共用编号和版本，网页与 PDF 分别由同一语言的源稿生成。复算分两步：解析脚本从本机原始日志提取每个请求的 Token 数与耗时，生成派生数据；情景脚本读取输入表（价格、汇率、硬件报价与各项假设）和派生数据，生成全部结果与三张图。复算不启动模型，也不调用付费服务。脚本、输入表、派生数据、逐项证据记录、双语术语表和修订记录保存在本文的本地工作包中；默认发布只包括中英文 PDF 和阅读说明，补充材料的公开范围以本文仓库的说明为准。

本机原始记录含本机路径和机器名，不公开。派生数据只有 Token 数、耗时和校验值，不含任何提示或回答内容；若随文公开，将同时附原始文件的 SHA-256。卡顿时生成的线程转储文件未复制。旧版 0.1.0 和 0.2.0 已归档，不再作为当前结论。

十四、AI 使用说明

本文 0.1.0 与 0.2.0 版由 Codex 辅助检索、计算、撰写、翻译和检查，具体后端模型未记录；10 月 12 日的本机安装与测速也由 Codex 执行。0.3.0 版由 Kiro 辅助复核来源、解析日志、重算情景、改写中英文全文，并检查网页与 PDF，所用后端模型同样未记录。上述检查都属于 AI 辅助自查，不是独立同行评审。实际使用日志来自这台机器使用者自己的工作，只保留 Token 数和耗时；本文没有参与者数据、访谈或已发生的收益记录。

参考文献

[1] Strata Contributors, 《Strata: Qwen3.8-Flash-Next on Consumer Hardware》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/Niko1221/Strata/blob/7695859aa13afb248bdb4d36f9b2e95707db079d/README.zh-CN.md

[2] KTransformers Contributors, 《Running DeepSeek-V4-Flash with SGLang and KT-Kernel》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://github.com/kvcache-ai/ktransformers/blob/a694e718e8b3ec2e221277d674e369f3be38d2a4/doc/en/DeepSeek-V4-Flash.md

[3] S. Yang 等, 《FreeToken: Efficient Edge-Native MoE Serving with Bandwidth-Adaptive Execution》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://arxiv.org/html/2608.16157v1

[4] S. Sanfilippo, 《DwarfStar: Qwen3.8 Flash Next》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://github.com/antirez/ds4/blob/ee7e8405232c8971000cc7ba2b945b00bf6d20d3/docs/QWEN38_FLASH_NEXT.md

[5] Command Code, 《GOAT Plan》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://commandcode.ai/docs/plans/goat

[6] OpenCode, 《Go》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://opencode.ai/v2/docs/console/go/

[7] DeepSeek, 《模型 & 价格》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://api-docs.deepseek.com/zh-cn/quick_start/pricing/

[8] VRAMGlass, 《GeForce RTX 3090 价格与二手行情》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://vramglass.com/zh/gpu/rtx-3090

[9] AKIBA PC Hotline!, 《DDR5 メモリの値上がりが目立つ、64GB×2 枚組は約 40 万円に急騰 [10 月前半のメモリ価格]》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://akiba-pc.watch.impress.co.jp/docs/price/monthly_repo/2148207.html

[10] ExchangeRate-API, 《Latest USD Reference Rates》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://open.er-api.com/v6/latest/USD

[11] Qwen Team, 《Qwen3.8-Flash-Next》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/QwenLM/Qwen3.8-Flash-Next/blob/69885871a64393807d988b27b1b5e380e8f28526/README.md

[12] Strata Contributors, 《Models: Sizes, Memory and Speed》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/Niko1221/Strata/blob/7695859aa13afb248bdb4d36f9b2e95707db079d/docs/MODELS.md

[13] Unsloth, 《Qwen3.8-Flash-Next: How to Run Locally》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://unsloth.ai/docs/models/qwen3.8-next

[14] FreeToken Contributors, 《FreeToken: Supported Models》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/FlashML-org/FreeToken/blob/ba31db2ea708b61d7313bccb3ee4adf9d11ecb90/docs/models.md

[15] Strata Contributors, 《Details: Missed Experts in a Verify Window》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/Niko1221/Strata/blob/7695859aa13afb248bdb4d36f9b2e95707db079d/docs/DETAILS.md

[16] Qwen Team, 《Qwen3.8-27B Model Card》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://huggingface.co/Qwen/Qwen3.8-27B

[17] ggml-org Contributors, 《llama.cpp》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/ggml-org/llama.cpp/tree/caa8191df159f764fb0160e3d2fc6be008948aee

[18] FastLLM Contributors, 《DeepSeek-V4 / DeepSeek-V4-Flash 部署指南》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/ztxz16/fastllm/blob/3d732fdbbaaf2360aafb9f9d529fdede4abc8b0e/docs/deepseek.md

[19] S. Sanfilippo, 《DwarfStar: Models and Vision》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://github.com/antirez/ds4/blob/ee7e8405232c8971000cc7ba2b945b00bf6d20d3/docs/MODELS.md

[20] S. Sanfilippo, 《DwarfStar: Performance and Benchmarking》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://github.com/antirez/ds4/blob/ee7e8405232c8971000cc7ba2b945b00bf6d20d3/docs/PERFORMANCE.md

[21] Strata Contributors, 《Strata README: DeepSeekV4.1-Flash-1017》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/Niko1221/Strata/blob/4b9e05a2a806a3fe24f7b2560d98626c37dade35/README.md

[22] huihui-ai, 《Huihui-Qwen3.8-Flash-Next-abliterated-GGUF: swift-IQ3_XXS》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://huggingface.co/huihui-ai/Huihui-Qwen3.8-Flash-Next-abliterated-GGUF/tree/4fdf4dc4d85184e2a51f5d33d7373ce053b3ec60/swift-IQ3_XXS

[23] P. E. Weidmann, 《Heretic》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://github.com/p-e-w/heretic/tree/80f81c90be92ab507d310fe4cb5f39745e6d357c

[24] VRAMGlass, 《数据方法》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://vramglass.com/zh/methodology

[25] VRAMGlass, 《GeForce RTX 5070 价格与二手行情》. 见于: 2026 年 10 月 27 日. [在线]. 载于: https://vramglass.com/zh/gpu/rtx-5070

[26] VRAMGlass, 《GeForce RTX 5090 价格与二手行情》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://vramglass.com/zh/gpu/rtx-5090

[27] VRAMGlass, 《Mac Studio M5 Max 128GB 价格与二手行情》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://vramglass.com/zh/gpu/mac-studio-m5-max-128gb

[28] VRAMGlass, 《DGX Spark 128GB 价格与二手行情》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://vramglass.com/zh/gpu/dgx-spark

[29] MemoryClearance, 《DDR4 or DDR5 for a Server Refresh in the 2026 Shortage》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://www.memoryclearance.com/blog/ddr4-or-ddr5-server-refresh-2026.html

[30] DeepSeek, 《Models & Pricing》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://api-docs.deepseek.com/quick_start/pricing/

[31] Command Code, 《Go Plan》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://commandcode.ai/docs/plans/go

[32] OpenCode, 《Low Cost Coding Models for Everyone》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://opencode.ai/go

[33] Command Code, 《Usage Limits》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://commandcode.ai/docs/resources/usage-limits

[34] Command Code, 《Pricing and Limits》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://commandcode.ai/docs/resources/pricing-limits

[35] Command Code, 《Frequently Asked Questions》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://commandcode.ai/docs/troubleshooting/faqs

[36] Google, 《Gemini Developer API Pricing》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://ai.google.dev/gemini-api/docs/pricing

[37] LiteLLM, 《Gemini 4 Argon API Pricing》. 见于: 2026 年 10 月 26 日. [在线]. 载于: https://models.litellm.ai/models/gemini-4-argon